AI-чат по базе знаний из облачных документов

Детер Климентий
Андрей Сызранов
Иванов Вячеслав
Коростелев Даниил
Вдовина Анастасия

Идея продукта

Веб-приложение, которое подключает Google Drive / Яндекс.Диск, автоматически индексирует документы и позволяет задавать вопросы в чате по их содержимому.

Ключевая ценность: **быстрый поиск знаний** в личных/командных файлах + **ответы с источниками**.

Кому это нужно?

- **Индивидуальные пользователи**: найти нужный фрагмент в своих документах за секунды
- **Команды**: общая база знаний с доступом по группам

Какие форматы собираемся поддерживать

- **MVP:** TXT, PDF, DOCX
- **Далее:** PPTX, XLSX/CSV

Схема работы

Индексация:

1. Подключение диска (OAuth) → скачивание файлов
2. Парсинг текста → разбиение на чанки → embeddings → сохранение в **PostgreSQL + pgvector**

Ответ на вопрос:

1. Embedding вопроса → векторный поиск top-K чанков (с фильтрацией по user/group)
2. LLM генерирует ответ **на основе найденного контекста** и возвращает **источники (документ/страница)**

Архитектура

Модульный монолит

Frontend: React SPA (Chat UI, Admin Panel, Auth UI)
Backend: Spring Boot 3 (Java 21), 5 модулей:

- **Auth** (Google OAuth2, JWT)
- **Storage** (Google Drive / Яндекс.Диск, токены, скачивание)
- **Indexing** (парсинг, чанкинг, embeddings, async + schedule)
- **Chat** (RAG pipeline, источники)
- **Admin** (пользователи/группы/диски/статусы)

DB: PostgreSQL 16 + **pgvector** (данные + вектора в одной БД)

-

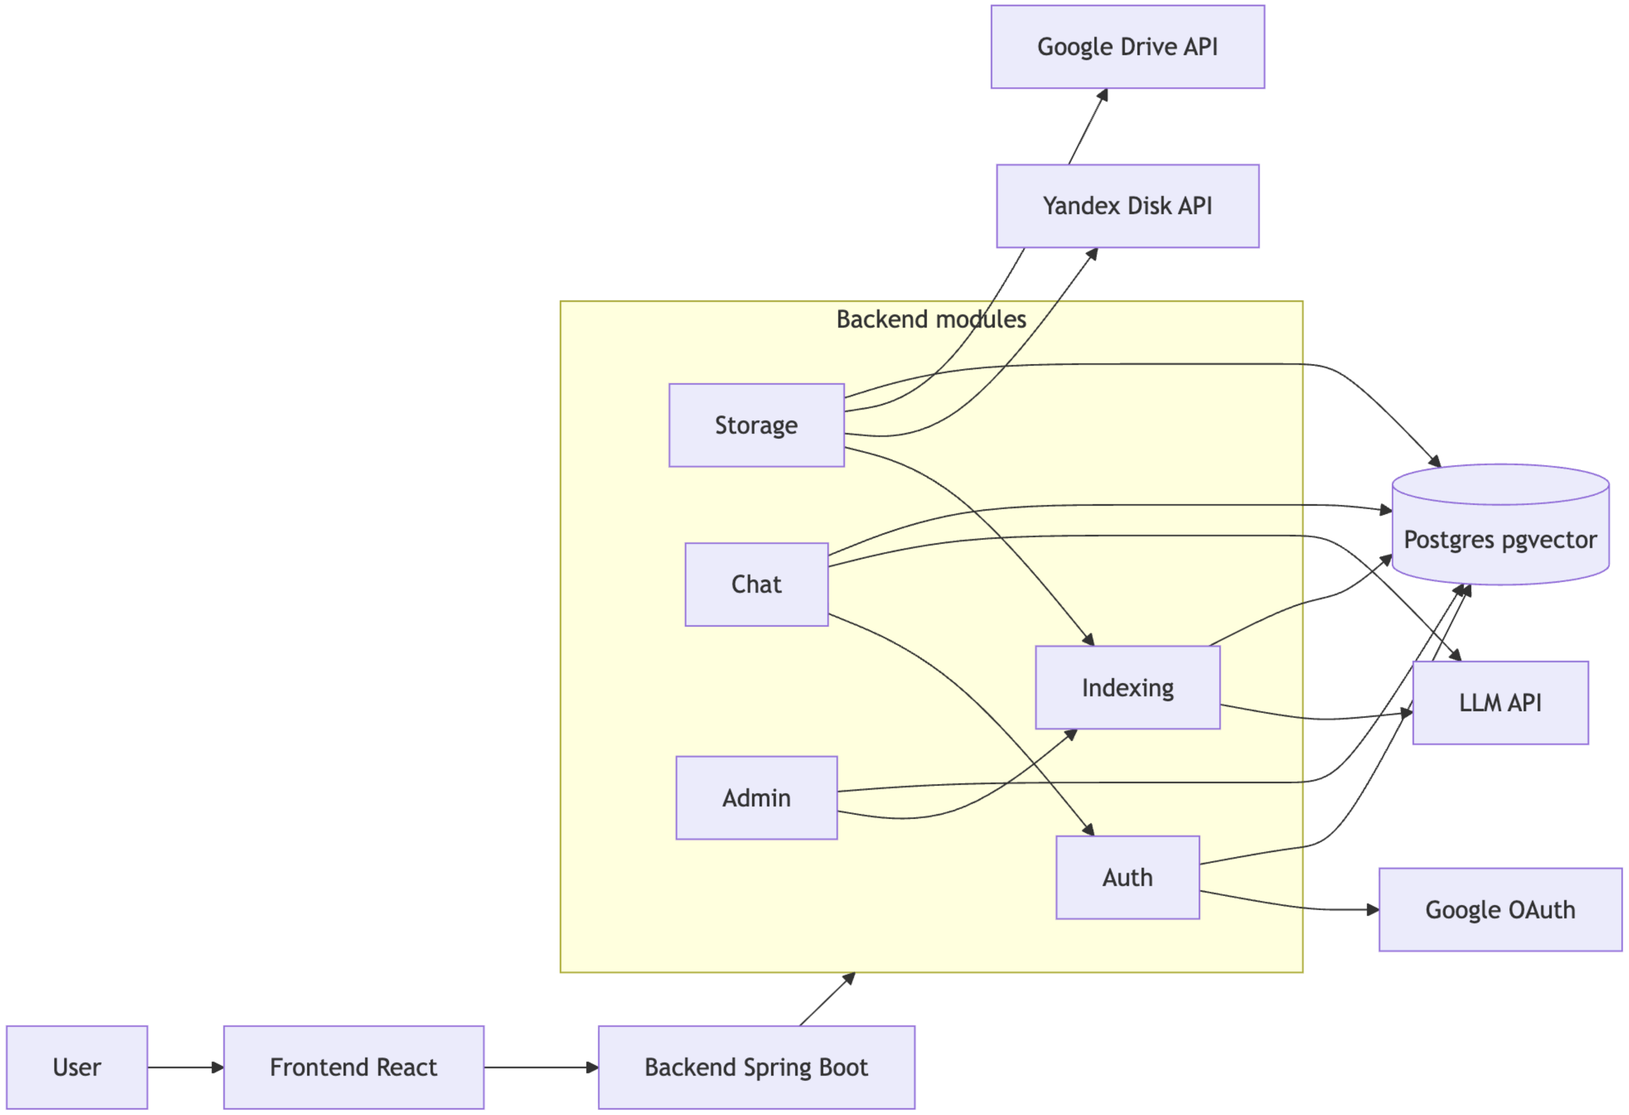
Google Drive API
Yandex Disk API
Backend modules
Storage
Chat
Indexing
Admin
Auth
Postgres pgvector
LLM API
Google OAuth
User
Frontend React
Backend Spring Boot

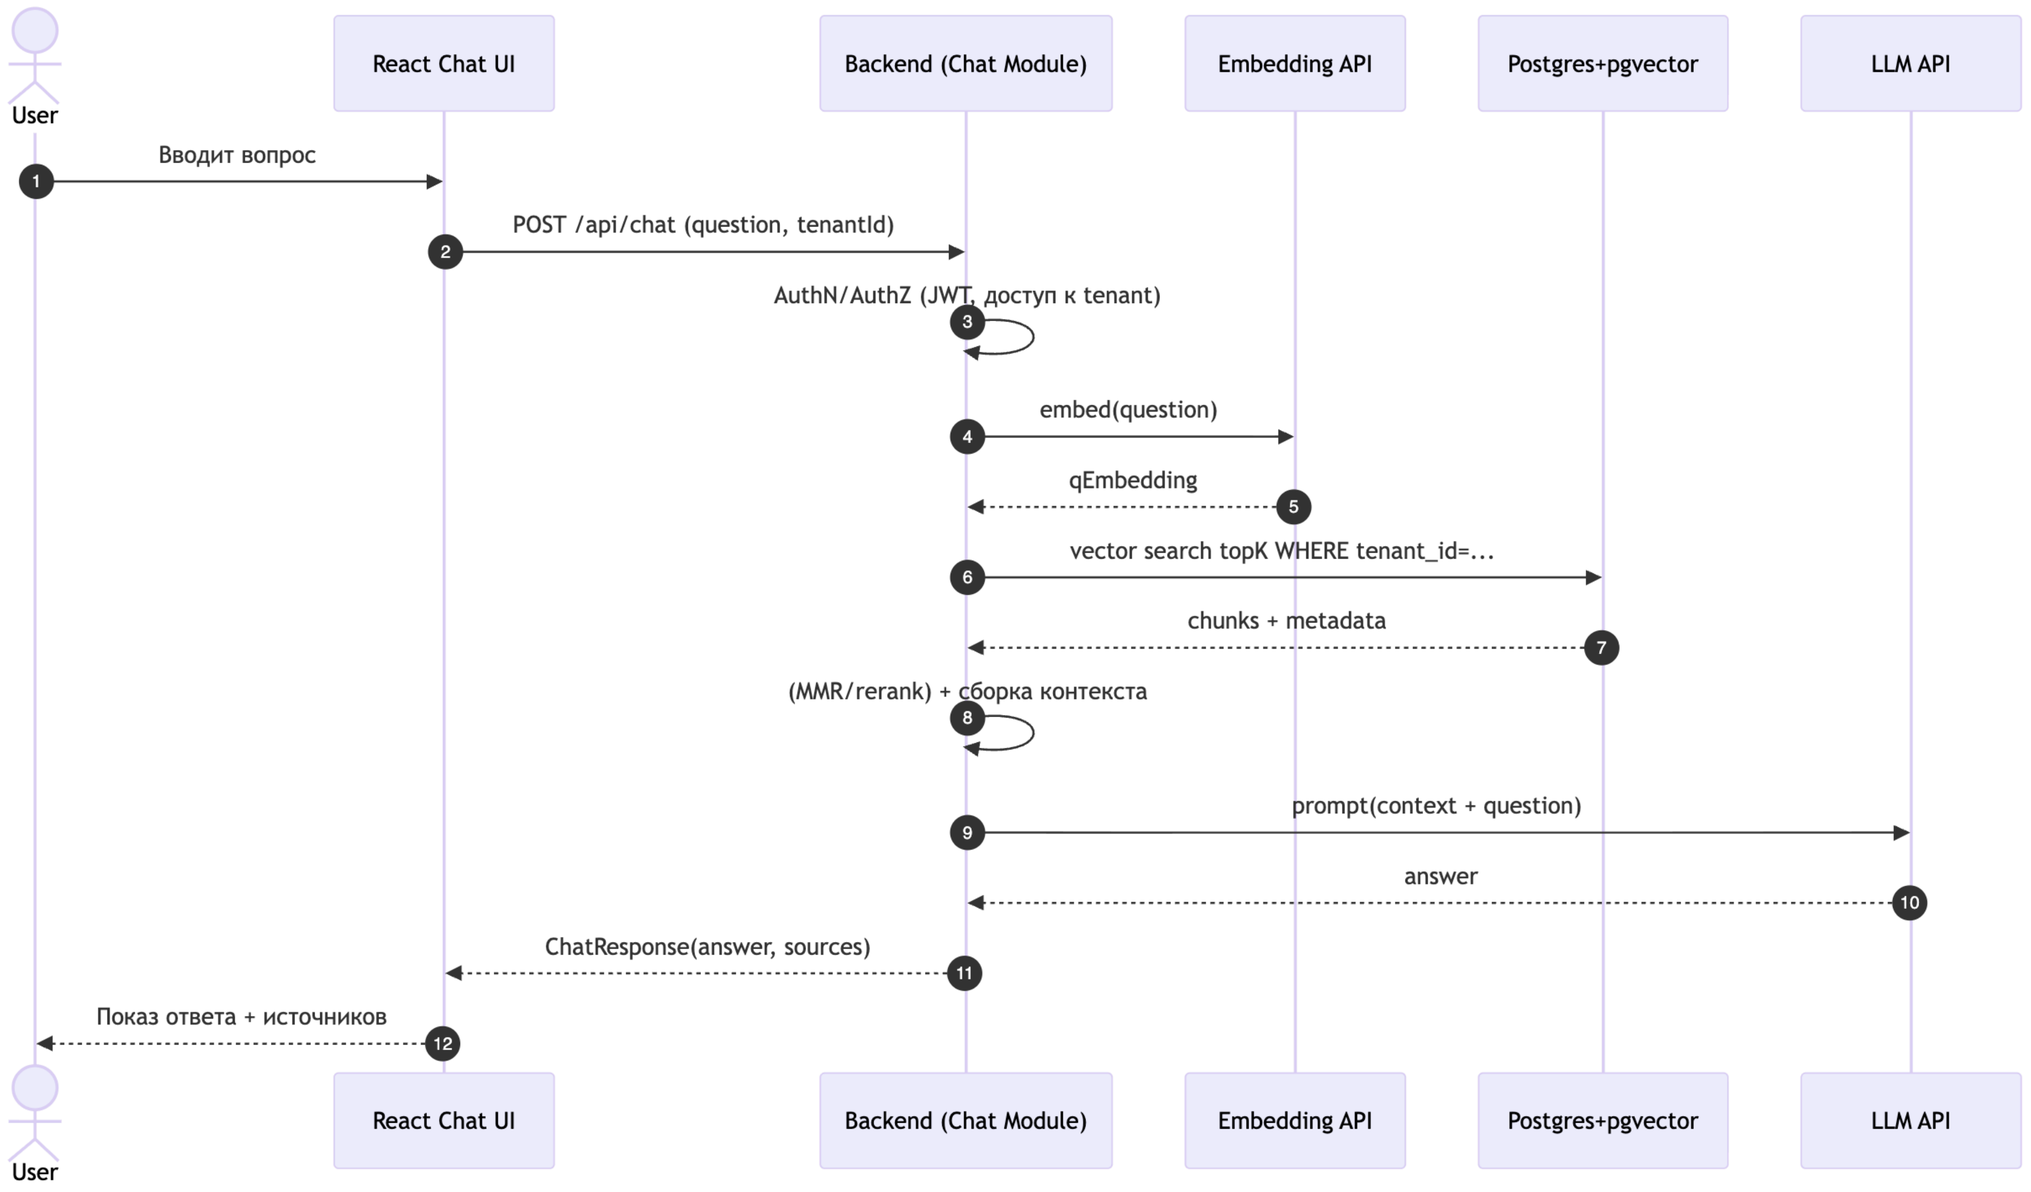
User
React Chat UI
Backend (Chat Module)
Embedding API
Postgres+pgvector
LLM API
1
Вводит вопрос
2
POST /api/chat (question, tenantId)
3
AuthN/AuthZ (JWT, доступ к tenant)
4
embed(question)
5
qEmbedding
6
vector search topK WHERE tenant_id=...
7
chunks + metadata
8
(MMR/rerank) + сборка контекста
9
prompt(context + question)
10
answer
11
ChatResponse(answer, sources)
12
Показ ответа + источников
User
React Chat UI
Backend (Chat Module)
Embedding API
Postgres+pgvector
LLM API

Технологии

Основные технологии

- Spring Boot 3, Java 21
- LangChain4j (LLM + embeddings + RAG абстракция)
- PostgreSQL + pgvector
- Apache PDFBox / Apache POI
- Docker / Docker Compose

Что ожидается от MVP

- Подключение дисков и управление ими
- Автоиндексация + ручная переиндексация
- AI-чат по документам
- Ответы с атрибуцией источников
- Изоляция данных по **user_id / group_id**